Perfilado automático de usuarios en corpus sociales sobre el movimiento *Black Lives Matter*

Nicolás Míguez García

Grado en Ingeniería Informática (Mención en Computación)

Patricia Martín Rodilla David Otero Freijeiro





Índice general

- Motivación y objetivos
- 2 Fundamentos
 - Estado del arte
 - Cojuntos de datos
 - Algoritmos de perfilado
- 3 Metodología y gestión del proyecto
- Desarrollo herramienta perfilado
 - Análisis
 - Diseño
 - Desarrollo
- 5 Análisis corpus #BLM
 - Algoritmo de Grivas
 - Algoritmo de Modaresi
 - Discusión de resultados
 - Conclusiones

Motivación

- Las RRSS han cambiado el modo de vida actual convirtiéndose uno de los principales medios de debate y difusión de información.
- La recopilación de textos y publicaciones de estas, ha dado lugar a la creación de 'archivos sociales', para la documentación de ciertos procesos.
- Con motivo de las protestas raciales surgidas en 2020 acerca del movimiento Black Lives Matter (#BLM) se ha creado una colección de referencia.
- Contiene +260.000 publicaciones de +90.00 usuarios de Reddit en inglés y español.
- Para el estudio del subconjunto en español se ha propuesto este TFG.

Objetivos

Definition (Author profiling)

Se conoce como **perfilado de usuarios** al procesamiento y análisis de textos para la identifiación de atributos como género o edad acerca de los mismo.

- Estudio del estado del arte del author profiling en materia de género y edad sobre textos en español.
- Comparación, selección e implementación de los algoritmos con mejor rendimiento.
- Construcción de un dashboard web para el perfilado y visualización de collecciones de usuarios.
- Estudio de resultados de perfilado sobre colección #BLM.

Índice general

- Motivación y objetivos
- Pundamentos
 - Estado del arte
 - Cojuntos de datos
 - Algoritmos de perfilado
- Metodología y gestión del proyecto
- Desarrollo herramienta perfilado
 - Análisis
 - Diseño
 - Desarrollo
- 5 Análisis corpus #BLM
 - Algoritmo de Grivas
 - Algoritmo de Modaresi
 - Discusión de resultados
 - Conclusiones

Fundamentos

Estado del arte

- El interés por el perfilado de usuarios se vió patente con algunos trabajos tempranos basados en blogs en inglés (2006 y 2007).
- Competiciones PAN organizadas por el grupo Webis: Perfilado de usuarios para género y edad, textos de Twitter y Blogs en español (2013 - 2016).
- Competiciones IberLEF (exclusivamente en español) organizadas por la SEPLN. perfilado de género e ideología política de usuarios en Twitter (2022).
- Estas proporcionaron los conjuntos de datos y algortimos a emplear en nuestro problema.

Fundamentos

Conjuntos de datos

	PAN-AP	2015	PAN-AP 2016	
Categoría	Training	Test	Training	Total
18-24	22	18	11	51
25-34	46	44	54	144
35-49	22	18	116	156
+50	10	8	41	59
Hombres	50	44	111	204
Mujeres	50	44	111	204
Total	100	88	222	410

Cuadro: Distribución de usuarios en función de edad y género en los conjuntos de entrenamiento utilizados.

Algoritmos de perfilado

1ª Aproximación:

- Ganador IberLEF 2022 (política)
- Red neuronal profunda.
- Embeddings de BETO y MarlA.
- Entrenamiento costoso (TPU).
- Requiere + datos entrenamiento.
- Peor rendimiento de los tres.

Algoritmos de perfilado

1ª Aproximación:

- Ganador IberLEF 2022 (política)
- Red neuronal profunda.
- Embeddings de BETO y MarlA.
- Entrenamiento costoso (TPU).
- Requiere + datos entrenamiento.
- Peor rendimiento de los tres.

2ª aproximación:

- 3º en PAN 2015 (personalidad).
- Máquina de soporte vectorial.
- Tf-idf n-gramas de 3 caracteres.
- El mejor en edad.

Algoritmos de perfilado

1ª Aproximación:

- Ganador IberLEF 2022 (política)
- Red neuronal profunda.
- Embeddings de BETO y MarlA.
- Entrenamiento costoso (TPU).
- Requiere + datos entrenamiento.
- Peor rendimiento de los tres.

2ª aproximación:

- 3º en PAN 2015 (personalidad).
- Máquina de soporte vectorial.
- Tf-idf n-gramas de 3 caracteres.
- El mejor en edad.

3^a aproximación:

- 2º en PAN 2016 (multi-género).
- Regresión logística.
- Tf-idf n-gramas distintos rangos
 + features estilísticas
 (puntuación y ortografía)
- Mejor en clasificación de género.

	Gér	nero	Edad		
Aprox	Асс	F1-w	Асс	F1-w	
				0.5657	
3 <u>a</u>	0.8120	0.8193	0.6423	0.5611	

Tabla: comparación aproximaciones 10-Fold Cross Validation

Índice general

- Motivación y objetivos
- 2 Fundamentos
 - Estado del arte
 - Cojuntos de datos
 - Algoritmos de perfilado
- Metodología y gestión del proyecto
- 4 Desarrollo herramienta perfilado
 - Análisis
 - Diseño
 - Desarrollo
- 5 Análisis corpus #BLM
 - Algoritmo de Grivas
 - Algoritmo de Modaresi
 - Discusión de resultados
 - Conclusiones

Elección y adaptaciones

Consideraciones proyecto

- Carácter innovador del proyecto.
- Falta recursos idioma español.
- Escaso conocimiento del dominio.
- Falta de acotación de requisitos.

Elección y adaptaciones

Consideraciones proyecto

- Carácter innovador del proyecto.
- Falta recursos idioma español.
- Escaso conocimiento del dominio.
- Falta de acotación de requisitos.

 \downarrow

Scrum

- Metodología ágil.
- Transparencia, inspección y adaptación.
- Roles, eventos y artefactos.

Elección y adaptaciones

Consideraciones proyecto

Adaptaciones Scrum

- Carácter innovador del proyecto.
- Falta recursos idioma español.
- Escaso conocimiento del dominio.
- Falta de acotación de requisitos.

 \downarrow

Scrum

- Metodología ágil.
- Transparencia, inspección y adaptación.
- Roles, eventos y artefactos.

Elección y adaptaciones

Consideraciones proyecto

- Carácter innovador del proyecto.
- Falta recursos idioma español.
- Escaso conocimiento del dominio.
- Falta de acotación de requisitos.

Scrum

- Metodología ágil.
- Transparencia, inspección y adaptación.
- Roles, eventos y artefactos.

Adaptaciones Scrum

- Product Owner → estudiante
- Scrum master → directores
- ullet Equipo de trabajo o estudiante

Elección y adaptaciones

Consideraciones proyecto

- Carácter innovador del proyecto.
- Falta recursos idioma español.
- Escaso conocimiento del dominio.
- Falta de acotación de requisitos.

\downarrow

Scrum

- Metodología ágil.
- Transparencia, inspección y adaptación.
- Roles, eventos y artefactos.

Adaptaciones Scrum

- Product Owner → estudiante
- Scrum master → directores
- ullet Equipo de trabajo o estudiante
- *Sprints* \rightarrow 3 semanas
- Carga de trabajo no uniforme (mayor últimos sprints)

Elección y adaptaciones

Consideraciones proyecto

- Carácter innovador del proyecto.
- Falta recursos idioma español.
- Escaso conocimiento del dominio.
- Falta de acotación de requisitos.

Scrum

- Metodología ágil.
- Transparencia, inspección y adaptación.
- Roles, eventos y artefactos.

Adaptaciones Scrum

- Product Owner → estudiante
- Scrum master → directores
- ullet Equipo de trabajo o estudiante
- ullet Sprints o 3 semanas
- Carga de trabajo no uniforme (mayor últimos sprints)
- ullet Daily review o autovaloración
- Product Backlog:
 - Fase de investigación → tareas técnicas (épica)
 - Desarrollo software → historias de usuario

Gestión del proyecto

Estimación y costes

- Se estimaron 9 sprints en total (se describen en detalle más adelante).
- Cada uno \approx 45 horas de trabajo (3 h/día)
- Recursos humanos: alumno (18€/h) y directores (31€/h).
- Ordenador portátil ≈ 428€

Gestión del proyecto

Estimación y costes

- Se estimaron 9 sprints en total (se describen en detalle más adelante).
- Cada uno \approx 45 horas de trabajo (3 h/día)
- Recursos humanos: alumno (18€/h) y directores (31€/h).
- Ordenador portátil ≈ 428€

Cálculo final:

Rol	Coste/hora	Tiempo de trabajo	Total
Equipo	18€	45h × 9 sprints	7.290 €
Project Managers	31€	$2 \times 1.5 h \times 9$ sprints	837 €
Material	_	_	428 €
Total	_	_	8.555 €

Índice general

- Motivación y objetivos
- 2 Fundamentos
 - Estado del arte
 - Cojuntos de datos
 - Algoritmos de perfilado
- Metodología y gestión del proyecto
- Desarrollo herramienta perfilado
 - Análisis
 - Diseño
 - Desarrollo
- 5 Análisis corpus #BLM
 - Algoritmo de Grivas
 - Algoritmo de Modaresi
 - Discusión de resultados
 - Conclusiones

Análisis

Historias de usuario

ld	Historia de usuario
E1	(Épica) Como usuario quiero perfilar el género y edad de
	los usuarios de una colección
H4	Como usuario quiero ver las estadísticas de edad en forma
	de gráfico de los usuarios perfilados en una colección
H7	Como usuario quiero ver las estadísticas de género en for-
	ma de gráfico de los usuarios perfilados en una colección
H2	Como usuario quiero elegir entre los distintos algoritmos
	de perfilado disponibles
H3	Como usuario quiero ver la lista de usuarios perfilados con
	su información asociada

Cuadro: Requisitos funcionales de la aplicación.

Análisis

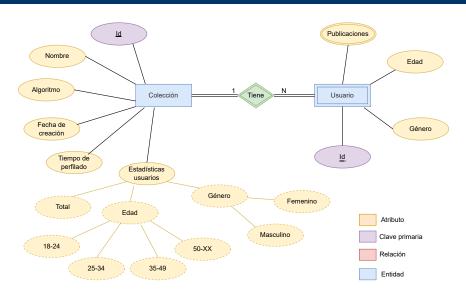
Historias de usuario

H6	Como usuario quiero ver las publicaciones de un usuario
	específico de la colección junto a sus datos demográficos
H5	Como usuario quiero ver detalles de la colección perfilada
	como nombre, tiempo, algoritmo y usuarios totales
H8	Como usuario quiero guardar las colecciones previamente
	perfiladas
H9	Como usuario quiero ver una lista ordenada temporal-
	mente que incluya datos generales de las colecciones previ-
	amente perfiladas
H10	Como usuario quiero filtrar según género y edad los datos
	de una colección

Cuadro: Requisitos funcionales de la aplicación.

Análisis

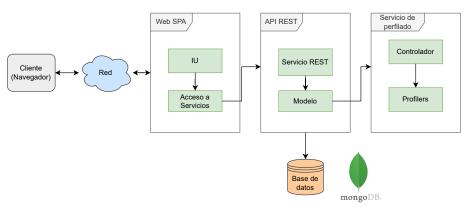
Modelo de datos (diagrama entidad - relación)



Diseño

Arquitectura global

Se ha optado por una arquitectura cliente-servidor distribuida en 3 capas.



Sprints

 Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)

- Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)
- Búsqueda, comparación y selección de algoritmos y datasets a emplear (4-3-2023 a 25-4-2023)

- Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)
- Búsqueda, comparación y selección de algoritmos y datasets a emplear (4-3-2023 a 25-4-2023)
- Primera aproximación y creación de scraper para descarga de dataset (25-4-2023 a 16-5-2023)

- Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)
- Búsqueda, comparación y selección de algoritmos y datasets a emplear (4-3-2023 a 25-4-2023)
- Primera aproximación y creación de scraper para descarga de dataset (25-4-2023 a 16-5-2023)
- Adaptación de algoritmos restantes y extracción de resultados (20-6-2023 a 11-7-2023)

- Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)
- Búsqueda, comparación y selección de algoritmos y datasets a emplear (4-3-2023 a 25-4-2023)
- Primera aproximación y creación de scraper para descarga de dataset (25-4-2023 a 16-5-2023)
- Adaptación de algoritmos restantes y extracción de resultados (20-6-2023 a 11-7-2023)
- Desarrollo del micro-servicio de perfilado (11-7-2023 a 1-8-2023)

- Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)
- Búsqueda, comparación y selección de algoritmos y datasets a emplear (4-3-2023 a 25-4-2023)
- Primera aproximación y creación de scraper para descarga de dataset (25-4-2023 a 16-5-2023)
- Adaptación de algoritmos restantes y extracción de resultados (20-6-2023 a 11-7-2023)
- Desarrollo del micro-servicio de perfilado (11-7-2023 a 1-8-2023)
- Inicio del frontend y creación de las primeras visualizaciones (1-8-2023 a 21-8-2023)

- Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)
- Búsqueda, comparación y selección de algoritmos y datasets a emplear (4-3-2023 a 25-4-2023)
- Primera aproximación y creación de scraper para descarga de dataset (25-4-2023 a 16-5-2023)
- Adaptación de algoritmos restantes y extracción de resultados (20-6-2023 a 11-7-2023)
- Desarrollo del micro-servicio de perfilado (11-7-2023 a 1-8-2023)
- Inicio del frontend y creación de las primeras visualizaciones (1-8-2023 a 21-8-2023)
- Lista y detalle de usuarios (21-8-2023 a 11-9-2023)

- Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)
- Búsqueda, comparación y selección de algoritmos y datasets a emplear (4-3-2023 a 25-4-2023)
- Primera aproximación y creación de scraper para descarga de dataset (25-4-2023 a 16-5-2023)
- Adaptación de algoritmos restantes y extracción de resultados (20-6-2023 a 11-7-2023)
- Desarrollo del micro-servicio de perfilado (11-7-2023 a 1-8-2023)
- Inicio del frontend y creación de las primeras visualizaciones (1-8-2023 a 21-8-2023)
- Lista y detalle de usuarios (21-8-2023 a 11-9-2023)
- Persistencia de las colecciones y rediseño del dashboard (11-9-2023 a 2-10-2023)

- Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)
- Búsqueda, comparación y selección de algoritmos y datasets a emplear (4-3-2023 a 25-4-2023)
- Primera aproximación y creación de scraper para descarga de dataset (25-4-2023 a 16-5-2023)
- Adaptación de algoritmos restantes y extracción de resultados (20-6-2023 a 11-7-2023)
- Desarrollo del micro-servicio de perfilado (11-7-2023 a 1-8-2023)
- Inicio del frontend y creación de las primeras visualizaciones (1-8-2023 a 21-8-2023)
- Lista y detalle de usuarios (21-8-2023 a 11-9-2023)
- Persistencia de las colecciones y rediseño del dashboard (11-9-2023 a 2-10-2023)
- Lista de colecciones y filtrado de usuarios por categoría (2-9-2023 a 23-10-2023)

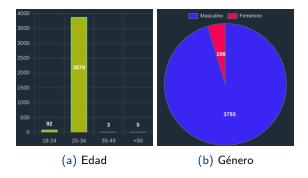
- Configuración del entorno e investigación del estado del arte (14-3-2023 a 4-4-2023)
- Búsqueda, comparación y selección de algoritmos y datasets a emplear (4-3-2023 a 25-4-2023)
- Primera aproximación y creación de scraper para descarga de dataset (25-4-2023 a 16-5-2023)
- Adaptación de algoritmos restantes y extracción de resultados (20-6-2023 a 11-7-2023)
- Desarrollo del micro-servicio de perfilado (11-7-2023 a 1-8-2023)
- Inicio del frontend y creación de las primeras visualizaciones (1-8-2023 a 21-8-2023)
- Lista y detalle de usuarios (21-8-2023 a 11-9-2023)
- Persistencia de las colecciones y rediseño del dashboard (11-9-2023 a 2-10-2023)
- Lista de colecciones y filtrado de usuarios por categoría (2-9-2023 a 23-10-2023)

Índice general

- Motivación y objetivos
- 2 Fundamentos
 - Estado del arte
 - Cojuntos de datos
 - Algoritmos de perfilado
- 3 Metodología y gestión del proyecto
- 4 Desarrollo herramienta perfilado
 - Análisis
 - Diseño
 - Desarrollo
- 6 Análisis corpus #BLM
 - Algoritmo de Grivas
 - Algoritmo de Modaresi
 - Discusión de resultados
 - Conclusiones

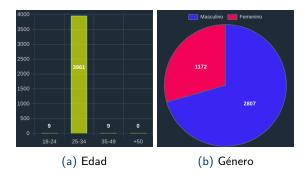
Resultados perfilado

Algoritmo de Grivas



Edad Género	18-24	25-34	35-49	+50	Total
Femenino	31	154	0	1	186
Masculino	61	3725	3	4	3793
Total	92	3879	3	5	3979

Algoritmo de Modaresi



Edad Género	18-24	25-34	35-49	+50	Total
Femenino	5	1162	5	0	1172
Masculino	4	2799	4	0	2807
Total	9	3961	9	0	3979

Discusión

 Gran desequilibrio en edad para grupo de 25-34 años (←) desequilibrio entrenamiento

Discusión

 Gran desequilibrio en edad para grupo de 25-34 años (←) desequilibrio entrenamiento

Reddit users and news users more likely to be male and young

	U.S. adults %	Reddit users %	Reddit news users %
Men	49	67	71
Women	51	33	29
18-29	22	64	59
30-49	34	29	33
50-64	25	6	7
65+	19	1	<1

Discusión

- Gran desequilibrio en edad para grupo de 25-34 años (←) desequilibrio entrenamiento
- Los usuarios varones representan más del 3/4 del corpus.

Reddit users and news users more likely to be male and young

	U.S. adults %	Reddit users %	Reddit news users %
Men	49	67	71
Women	51	33	29
18-29	22	64	59
30-49	34	29	33
50-64	25	6	7
65+	19	1	<1

Discusión

- Gran desequilibrio en edad para grupo de 25-34 años (←) desequilibrio entrenamiento
- Los usuarios varones representan más del 3/4 del corpus.

Reddit users and news users more likely to be male and young

	U.S. adults %	Reddit users %	Reddit news users %
Men	49	67	71
Women	51	33	29
18-29	22	64	59
30-49	34	29	33
50-64	25	6	7
65+	19	1	<1

Discusión

- Gran desequilibrio en edad para grupo de 25-34 años (←) desequilibrio entrenamiento
- Los usuarios varones representan más del 3/4 del corpus.
- 48.98 % corpus tienen menos de 2 publicaciones. El 80 % menos de 5.



Reddit users and news users more likely to be male and young

	U.S. adults %	Reddit users %	Reddit news users %
Men	49	67	71
Women	51	33	29
18-29	22	64	59
30-49	34	29	33
50-64	25	6	7
65+	19	1	<1

Discusión

- Gran desequilibrio en edad para grupo de 25-34 años (←) desequilibrio entrenamiento
- Los usuarios varones representan más del 3/4 del corpus.
- ullet Distribución usuarios Reddit \Longrightarrow distribución corpus.
- 48.98 % corpus tienen menos de 2 publicaciones. El 80 % menos de 5.

 Baja fiabilidad del perfilado que puede acentuar los desequilibrios.

Reddit users and news users more likely to be male and young

	U.S. adults %	Reddit users %	Reddit news users %
Men	49	67	71
Women	51	33	29
18-29	22	64	59
30-49	34	29	33
50-64	25	6	7
65+	19	1	<1

Discusión

- Gran desequilibrio en edad para grupo de 25-34 años (←) desequilibrio entrenamiento
- Los usuarios varones representan más del 3/4 del corpus.
- 48.98% corpus tienen menos de 2 publicaciones. El 80% menos de 5.



- Baja fiabilidad del perfilado que puede acentuar los desequilibrios.
- Preferible a mostrar unos resultados no representativos.

Reddit users and news users more likely to be male and young

	U.S. adults %	Reddit users %	Reddit news users %
Men	49	67	71
Women	51	33	29
18-29	22	64	59
30-49	34	29	33
50-64	25	6	7
65+	19	1	<1

Discusión

- Gran desequilibrio en edad para grupo de 25-34 años (←) desequilibrio entrenamiento
- Los usuarios varones representan más del 3/4 del corpus.
- 48.98 % corpus tienen menos de 2 publicaciones. El 80 % menos de 5.



- Baja fiabilidad del perfilado que puede acentuar los deseguilibrios.
- Preferible a mostrar unos resultados no representativos.
- Resultados similares a corpus inglés: usuarios mayoritariamente varones entre 25-34 años.

Reddit users and news users more likely to be male and young

	U.S. adults %	Reddit users %	Reddit news users %
Men	49	67	71
Women	51	33	29
18-29	22	64	59
30-49	34	29	33
50-64	25	6	7
65+	19	1	<1

Índice general

- Motivación y objetivos
- Pundamentos
 - Estado del arte
 - Cojuntos de datos
 - Algoritmos de perfilado
- 3 Metodología y gestión del proyecto
- 4 Desarrollo herramienta perfilado
 - Análisis
 - Diseño
 - Desarrollo
- 5 Análisis corpus #BLM
 - Algoritmo de Grivas
 - Algoritmo de Modaresi
 - Discusión de resultados
 - Conclusiones

Conclusiones

Evaluación estado actual y lecciones aprendidas

Resultados:

- Se exploraron y probaron varios algoritmos del estado del arte del perfilado automático de usuarios con buen rendimiento.
- Se creó una herramienta mediante unas buenas prácticas de ingeniería que a la vez es escalable, extensible y portable con una interfaz intuitiva y accesible.
- Se analizó el corpus de referencia sobre #BLM de forma satisfactoria.

Conclusiones

Evaluación estado actual y lecciones aprendidas

Resultados:

- Se exploraron y probaron varios algoritmos del estado del arte del perfilado automático de usuarios con buen rendimiento.
- Se creó una herramienta mediante unas buenas prácticas de ingeniería que a la vez es escalable, extensible y portable con una interfaz intuitiva y accesible.
- Se analizó el corpus de referencia sobre #BLM de forma satisfactoria.

Lecciones aprendidas:

- Importancia del seguimiento de unas pautas metodológicas estrictas (primera fase).
- Conocimientos que se valoraron en retrospectiva y asentaron gracias a este proyecto.
- Perspectiva mucho más amplia de mis posibilidades en esta profesión.

Mejora algoritmos perfilado

Aumento tamaño y calidad corpus entrenamiento.

Mejora algoritmos perfilado

- Aumento tamaño y calidad corpus entrenamiento.
- Uso de algoritmos de clasificación basados en transformers como LLM.

Mejora algoritmos perfilado

- Aumento tamaño y calidad corpus entrenamiento.
- Uso de algoritmos de clasificación basados en transformers como LLM.
- Perfilado sobre rasgos de personalidad, nivel de vida, educación...

Ampliación funcionalidad:

 Perfilado de forma asíncrona por parte del usuario.

Mejora algoritmos perfilado

- Aumento tamaño y calidad corpus entrenamiento.
- Uso de algoritmos de clasificación basados en transformers como LLM.
- Perfilado sobre rasgos de personalidad, nivel de vida, educación...

Ampliación funcionalidad:

- Perfilado de forma asíncrona por parte del usuario.
- Exportar datos del dashboard, incluyendo gráficos y visualizaciones.

Mejora algoritmos perfilado

- Aumento tamaño y calidad corpus entrenamiento.
- Uso de algoritmos de clasificación basados en transformers como LLM.
- Perfilado sobre rasgos de personalidad, nivel de vida, educación...

Ampliación funcionalidad:

- Perfilado de forma asíncrona por parte del usuario.
- Exportar datos del dashboard, incluyendo gráficos y visualizaciones.
- Visualización de características de escritura en dashboard sobre usuarios perfilados.

¡Gracias por su atención!